

1 Aproximação dos mínimos quadrados

- Forma geral do problema

$$\text{minimizar } \sum_{j=1}^m (f(x_j) - M(x_j; c_i))^2.$$

- Modelo polinomial

$$p_n(x) = c_0 P_0(x) + c_1 P_1(x) + c_2 P_2(x) + \cdots + c_n P_n(x).$$

- Polinómios ortogonais

$$P_{i+1}(x) = (x - B_i) P_i(x) - \mathbb{C}_i P_{i-1}(x), i = 0, \dots, n-1, P_{-1}(x) = 0, P_0(x) = 1$$

$$B_i = \frac{\sum_{j=1}^m x_j P_i^2(x_j)}{\sum_{j=1}^m P_i^2(x_j)}, \text{ para todo o } i \quad \mathbb{C}_0 = 0 \text{ e } \mathbb{C}_i = \frac{\sum_{j=1}^m P_i^2(x_j)}{\sum_{j=1}^m P_{i-1}^2(x_j)} \text{ para } i > 0.$$

- Coeficientes do polinómio

$$c_i = \frac{\sum_{j=1}^m f_j P_i(x_j)}{\sum_{j=1}^m P_i^2(x_j)}, \quad i = 0, 1, \dots, n.$$

- Modelo linear não polinomial

$$M(x; c_1, \dots, c_n) = c_1 \Phi_1(x) + c_2 \Phi_2(x) + \cdots + c_n \Phi_n(x).$$

- Sistema das equações normais

$$\begin{pmatrix} \sum_{j=1}^m \Phi_1^2(x_j) & \sum_{j=1}^m \Phi_2(x_j) \Phi_1(x_j) & \cdots & \sum_{j=1}^m \Phi_n(x_j) \Phi_1(x_j) \\ \sum_{j=1}^m \Phi_1(x_j) \Phi_2(x_j) & \sum_{j=1}^m \Phi_2^2(x_j) & \cdots & \sum_{j=1}^m \Phi_n(x_j) \Phi_2(x_j) \\ \cdots & \cdots & \ddots & \cdots \\ \sum_{j=1}^m \Phi_1(x_j) \Phi_n(x_j) & \sum_{j=1}^m \Phi_2(x_j) \Phi_n(x_j) & \cdots & \sum_{j=1}^m \Phi_n^2(x_j) \end{pmatrix} \begin{pmatrix} c_1 \\ c_2 \\ \cdots \\ c_n \end{pmatrix} = \begin{pmatrix} \sum_{j=1}^m f_j \Phi_1(x_j) \\ \sum_{j=1}^m f_j \Phi_2(x_j) \\ \cdots \\ \sum_{j=1}^m f_j \Phi_n(x_j) \end{pmatrix}.$$

2 Mínimos vs máximos

$$\max f(x) = -\min(-f(x)), \quad x^* = \underbrace{\arg \max (f(x))}_{\text{maximizante}} = \underbrace{\arg \min (-f(x))}_{\text{minimizante}}$$

3 Método de DSC

Dados: x_1, δ, ε

1. **Há sucesso na procura para a direita** ($f(x_2) \leq f(x_1)$), **com** $x_2 = x_1 + \delta$: Continuar a procura para a direita (x_2, x_3, \dots), dobrando sempre o tamanho do passo ($2\delta, 4\delta, 8\delta, \dots$), até o valor da função subir. Ir para 4.
2. **Não há sucesso na procura para a direita, mas há sucesso na procura para a esquerda** ($f(x_{-1}) \leq f(x_1)$), **com** $x_{-1} = x_1 - \delta$: Continuar a procura para a esquerda (x_{-2}, x_{-3}, \dots) dobrando sempre o tamanho do passo ($2\delta, 4\delta, 8\delta, \dots$), até o valor da função subir. Ir para 4.
3. **Não há sucesso na procura em nenhum dos sentidos**: Ordenar os pontos por ordem crescente, que passam a chamar-se $\mathbf{x}_1, \mathbf{x}_2$ e \mathbf{x}_3 . Ir para 6.
4. x_m = média dos dois últimos pontos calculados. Ir para 5.
5. escolha dos 3 pontos para a interpolação quadrática:
 - i. ordenar os quatro pontos por ordem crescente
 - ii. comparar os valores da função dos pontos interiores
 - iii. eliminar o ponto que estiver mais longe do valor mais baixo. Se os valores forem iguais elimina-se o ponto da direita. Os pontos selecionados, ordenados por ordem crescente, passam a chamar-se $\mathbf{x}_1, \mathbf{x}_2$ e \mathbf{x}_3 .
 - iv. $\Delta = \mathbf{x}_3 - \mathbf{x}_2 = \mathbf{x}_2 - \mathbf{x}_1$.
 - v. Ir para 6.
6. $x^*(q) = \mathbf{x}_2 + \Delta \frac{f(\mathbf{x}_1) - f(\mathbf{x}_3)}{2(f(\mathbf{x}_3) - 2f(\mathbf{x}_2) + f(\mathbf{x}_1))}$
7. Verificar o critério de paragem: $\Delta \leq \varepsilon$
 - i. O critério de paragem não se verifica.
 $x_1 = x^*(q)$. Fazer $\delta = M\delta$ e ir para 1.
 - ii. O critério de paragem verifica-se.
 $x^* \approx x^*(q)$. Terminar.

4 Condições de otimalidade

- Vetor gradiente de $f(x)$
- Matriz Hessiana de $f(x)$

$$\nabla f(x) = \begin{pmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \\ \vdots \\ \frac{\partial f}{\partial x_n} \end{pmatrix}. \quad \nabla^2 f(x) = \begin{pmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_2 \partial x_1} & \cdots & \frac{\partial^2 f}{\partial x_n \partial x_1} \\ \frac{\partial^2 f}{\partial x_1 \partial x_2} & \frac{\partial^2 f}{\partial x_2^2} & \cdots & \frac{\partial^2 f}{\partial x_n \partial x_2} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_1 \partial x_n} & \frac{\partial^2 f}{\partial x_2 \partial x_n} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{pmatrix}.$$

- Condição necessária e suficiente de primeira ordem

$$\nabla f(x^*) = 0$$

- Condição necessária de segunda ordem para que x^* seja minimizante/maximizante

$\nabla^2 f(x^*)$ é semi-definida positiva/semi-definida negativa.

- Condição suficiente de segunda ordem para que x^* seja minimizante/maximizante $\nabla^2 f(x^*)$ é definida positiva/definida negativa

- $\nabla^2 f(x^*)$ semi-definida positiva $\Rightarrow x^*$ é minimizante ou ponto sela de $f(x)$;
- $\nabla^2 f(x^*)$ é semi-definida negativa $\Rightarrow x^*$ é maximizante ou ponto sela de $f(x)$
- $\nabla^2 f(x^*)$ é indefinida $\Rightarrow x^*$ é ponto sela de $f(x)$.

- Uma matriz diz-se

- **definida positiva** se todos os determinantes das submatrizes principais dessa matriz são positivos,
- **definida negativa** se os determinantes das submatrizes principais dessa matriz são alternadamente negativos e positivos, sendo o determinante da primeira submatriz negativo,
- **semi-definida positiva** se os determinantes das submatrizes principais dessa matriz são positivos ou iguais a zero,
- **semi-definida negativa** se os determinantes das submatrizes principais dessa matriz são alternadamente negativos e positivos, sendo o determinante da primeira submatriz negativo, ou iguais a zero,
- **indefinida** nos restantes casos.

5 Métodos do gradiente

- Algoritmo genérico

ler: x^1 e ε , $k \leftarrow 0$

repetir

$k \leftarrow k + 1$

calcular d^k

calcular α^k

$x^{k+1} \leftarrow x^k + \alpha^k d^k$

até $\|\nabla f(x^{k+1})\|_2 \leq \varepsilon$

$x^* \leftarrow x^{k+1}$, $f(x^*) \leftarrow f(x^{k+1})$

- Critério de Armijo

ler: x^k , d^k , $f(x^k)$, $\nabla f(x^k)$ e μ

$\alpha \leftarrow 2$

repetir

$\alpha \leftarrow 0.5 \times \alpha$

$x^{\text{aux}} \leftarrow x^k + \alpha d^k$

até $f(x^{\text{aux}}) \leq f(x^k) + \mu \alpha \nabla f(x^k)^T d^k$

$\alpha^k \leftarrow \alpha$

- Segurança-Newton

ler: x^k e η

resolver o sistema linear Newton

$\nabla^2 f(x^k) d_N^k = -\nabla f(x^k)$ por EGPP

se $\exists d_N^k$ (o sistema linear tem solução única) **então**

se $|\nabla f(x^k)^T d_N^k| \leq \eta$ **então**

$d_{SN}^k = -\nabla f(x^k)$

senão

se $\nabla f(x^k)^T d_N^k > \eta$ **então**

$d_{SN}^k = -d_N^k$

senão

$d_{SN}^k = d_N^k$

fim se

fim se

senão

$d_{SN}^k = -\nabla f(x^k)$

fim se

- Quasi-Newton

ler: x^k

se $k = 1$ **então**

$H^k = I$

senão

$s^{k-1} \leftarrow x^k - x^{k-1}$

$y^{k-1} \leftarrow \nabla f(x^k) - \nabla f(x^{k-1})$

atualizar H^k por DFP ou BFGS

fim se

$d_{QN}^k \leftarrow -H^k \nabla f(x^k)$

se $\nabla f(x^k)^T d_{QN}^k \geq 0$ **então**

$d_{QN}^k \leftarrow -\nabla f(x^k)$

fim se

- Fórmula DFP: $H^{(k)} = H^{(k-1)} - \frac{H^{(k-1)} y^{(k-1)} y^{(k-1)T} H^{(k-1)}}{y^{(k-1)T} H^{(k-1)} y^{(k-1)}} + \frac{s^{(k-1)} s^{(k-1)T}}{s^{(k-1)T} y^{(k-1)}}$

- Fórmula BFGS: $H^{(k)} = \left(I - \frac{s^{(k-1)} y^{(k-1)T}}{s^{(k-1)T} y^{(k-1)}} \right) H^{(k-1)} \left(I - \frac{y^{(k-1)} s^{(k-1)T}}{s^{(k-1)T} y^{(k-1)}} \right) + \frac{s^{(k-1)} s^{(k-1)T}}{s^{(k-1)T} y^{(k-1)}}$

6 Método de Nelder-Mead

1. Ordenar o simplex por ordem crescente dos valores da função.

- X_1 – o melhor vértice;
- X_n – o segundo pior vértice;
- X_{n+1} – o pior vértice.

$$x_r = (1 + \alpha)\bar{x} - \alpha X_{n+1}, \quad x_e = \gamma x_r + (1 - \gamma)\bar{x}, \quad \hat{x}_c = \beta x_r + (1 - \beta)\bar{x}, \quad x_c = \beta X_{n+1} + (1 - \beta)\bar{x}.$$

$$\alpha = 1, \beta = 0.5, \gamma = 2$$

$$\text{Encolher o simplex: } x_i = \frac{X_i + X_1}{2}$$

Em cada iteração fazer:

$$x_r \left\{ \begin{array}{ll} \begin{array}{l} \text{muito bom} \\ f(x_r) < f(X_1) \end{array} & \Rightarrow x_e \left\{ \begin{array}{ll} \text{muito bom} & \Rightarrow \text{aceita-se } x_e \\ f(x_e) < f(X_1) & \\ \text{caso contrário} & \Rightarrow \text{aceita-se } x_r \end{array} \right. \\ \\ \begin{array}{l} \text{bom} \\ f(X_1) \leq f(x_r) < f(X_n) \end{array} & \Rightarrow \text{aceita-se } x_r \\ \\ \begin{array}{l} \text{fraco} \\ f(X_n) \leq f(x_r) < f(X_{n+1}) \end{array} & \Rightarrow \hat{x}_c \left\{ \begin{array}{ll} \text{bom} & \Rightarrow \text{aceita-se } \hat{x}_c \\ f(\hat{x}_c) < f(X_n) & \\ \text{caso contrário} & \Rightarrow \text{encolhe-se o simplex} \end{array} \right. \\ \\ \begin{array}{l} \text{muito fraco} \\ f(x_r) \geq f(X_{n+1}) \end{array} & \Rightarrow x_c \left\{ \begin{array}{ll} \text{bom} & \Rightarrow \text{aceita-se } x_c \\ f(x_c) < f(X_n) & \\ \text{caso contrário} & \Rightarrow \text{encolhe-se o simplex} \end{array} \right. \end{array} \right.$$

Até se verificar critério de paragem: $\frac{1}{\Delta} \max_{2 \leq i \leq n+1} \|X_i - X_1\|_2 \leq \varepsilon$, com $\Delta = \max(1, \|X_1\|_2)$.

Para verificar o critério de paragem é necessário que o simplex se encontre ordenado.

Quando se verificar o critério de paragem para-se e $x^* \approx X_1$.